

(الف) صحیح است در RL ، R و T را نمی دانیم و در حالت

$active RL$ سعی خودمان باید $episode$ ها را شروع کرده و بررسی کنیم
و در حالت $passive RL$ سعی می‌کنیم π به عنوان $behavioral Policy$ داریم

که طبق آن $sample$ جمع می‌کنیم البته اگر سخت‌گیری کنیم می‌توان

گزاره را غلط گرفت چون حالتی جمع می‌کنیم که بدون آینده ما کاری در

جمع می‌کنیم با داشتن تعدادی $sample$ از π مشخص می‌کنیم که شخص

دیگری قبلاً جمع کرده است می‌توان s^* را پیدا کرد ولی در آن حالت سعی

شخص دیگری قبلاً به شکل آنهایی که $sample$ ها را به دست آورده

(ب) غلط حالتی را فرض کنید که تمامی $state$ ها و $Reward$

ها مثل هم باشند درین صورت هر پالیسی یک پالیسی بهینه است

(ج) غلط، این الگوریتم فارغ از تعیین T و R متغیر

به دنبال تخمین زدن γ^* است در کل RL به ۲ دسته

model-free و model-based تقسیم می شود که تقریباً تمام الگوریتم های کاربردی

آن model-free هستند

(د) صحیح. طبقاً γ^* از تمامی γ های دیگر بهتر است پس γ^*

قطعا از γ^2 بهتر خواهد بود که به راحتی با برهان حالت قابل اثبات

است: فرض کنید γ از γ^2 داریم $\gamma_{(s)}^2 < \gamma_{(s)}^*$:

یعنی وجود دارد a به طوری که $\gamma_{(s)}^2 = Q_{(s,a)}^2$

پس $Q_{(s,a)}^* < \gamma_{(s)}^*$ که ب یعنی γ_s^* اینه است.

رود و میتوان حد اقل به گام Policy improvement دانست که فرض

راستش می که از طرفی Policy improvement همیشه γ معوضی است

و بعد از converge کردن دیگر تقریبی که و آن بین مقدارشان γ^*

است.

(۳) الف

$$E_{s \sim P(s), a \sim \pi_0(s,a)} \left[\frac{\pi_1(s,a)}{\pi_0(s,a)} R_{(s,a)} \right] =$$

$$\sum \frac{\pi_1(s,a)}{\pi_0(s,a)} R_{(s,a)} \times P_{(s)} P(a|s) =$$

$$\sum \frac{\pi_1(s,a)}{\cancel{\pi_0(s,a)}} R_{(s,a)} P_{(s)} \cancel{\pi_0(s,a)} =$$

$$\sum R_{(s,a)} P_{(s)} \pi_1(s,a) = E_{s \sim P(s), a \sim \pi_1(s,a)} [R_{(s,a)}]$$

یعنی این ۲ امید ریاضی با هم برابر هستند

تخمین گر معرفی شود importance sampling estimator است که به شکل :

$$\hat{J} = \frac{1}{n} \sum_{i=1}^n \frac{\pi_1(s,a)}{\pi_0(s,a)} R_{(s,a)}$$

معملاً طبق قانون اعداد بزرگ در $n \rightarrow \infty$

$$\hat{J} = E_{s \sim P(s), a \sim \pi_0(s,a)} \left[\frac{\pi_1(s,a)}{\pi_0(s,a)} R_{(s,a)} \right]$$

برای نشان دادن سازگاری باید نشان دهم که

$$\lim_{n \rightarrow \infty} P(\hat{\theta} - E[R(s, \alpha)] > \epsilon) = 0$$

$s \in P(s) \text{ و } \alpha \in \mathcal{A}(s, \alpha)$

که می‌توان به جای $\hat{\theta}$ ، $E\left[\frac{\alpha_1(s, \alpha)}{\alpha_0(s, \alpha)} R(s, \alpha)\right]$ را جایگزین کرد

را گزینیم و این یعنی کافی است نشان دهم امید ریاضی این

آسانی است یعنی همین چیزی که اثبات کردیم

$$E\left[\frac{\alpha_1(s, \alpha)}{\alpha_0(s, \alpha)} R(s, \alpha)\right] = E[R(s, \alpha)]$$

$s \in P(s) \text{ و } \alpha \in \mathcal{A}(s, \alpha)$

پس این تخمین سازگار است

(ب) این تخمین به شکل

$$\hat{\theta} = \frac{\frac{1}{n} \sum_{i=1}^n \frac{\alpha_1(s_i, \alpha)}{\alpha_0(s_i, \alpha)} R(s_i, \alpha)}{\frac{1}{n} \sum_{i=1}^n \frac{\alpha_1(s_i, \alpha)}{\alpha_0(s_i, \alpha)}}$$

مثل بخشی الف باید نشان داد که

$$\lim_{n \rightarrow \infty} P(\hat{\theta} - E[R(s, \alpha)] > \epsilon) = 0$$

$s \in P(s) \text{ و } \alpha \in \mathcal{A}(s, \alpha)$

چسی دارع

$$\lim_{h \rightarrow \infty} \frac{1}{h} \sum_{i=1}^h \frac{z_1(s, a)}{z_0(s, a)} R(s, a) =$$

طبق الف

$$E_{s \sim P(s), a \sim z_0(s, a)} \left[\frac{z_1(s, a)}{z_0(s, a)} R(s, a) \right] = E_{s \sim P(s), a \sim z_1(s, a)} [R(s, a)]$$

$$\lim_{h \rightarrow \infty} \frac{1}{h} \sum_{i=1}^h \frac{z_1(s, a)}{z_0(s, a)} = E \left[\frac{z_1(s, a)}{z_0(s, a)} \right]$$

$$= \sum \frac{z_1(s, a)}{z_0(s, a)} p(s) p(a|s) = \sum \frac{z_1(s, a)}{z_0(s, a)} p(s) \cancel{z_0(s, a)}$$

$$= \sum z_1(s, a) p(s) = 1 \rightarrow \text{جمع همه احتمالات}$$

$$\Rightarrow \lim_{h \rightarrow \infty} \hat{J} = \frac{E_{s \sim P(s), a \sim z_1(s, a)} [R(s, a)]}{1} = E_{s \sim P(s), a \sim z_1(s, a)} [R(s, a)]$$

چسی این مورد نیز نشان داده شد برابر همان امید ریاضی صورت

سوال است و این تخصیص نیز بازگذاشت.

(ج) کافی است که $n=1$ باشد (فقط یک نمونه دانه باشد)

$$\hat{J} = \frac{\frac{1}{n} \sum_{i=1}^n \frac{r_1(s, a_i)}{r_0(s, a_i)} R(s, a_i)}{\frac{1}{n} \sum_{i=1}^n \frac{r_1(s, a_i)}{r_0(s, a_i)}} = R(s, a_1)$$

اگر s از همان یک نمونه باشد

در این حالت a_1 و a_i از توزیع r_0 آمده اند و با E_{r_0} برابر

است و با E_{r_1} برابر نیست که یعنی bias داریم

(د) ابتدا فرض میکنیم این $R(s)$ باشد یعنی هر

وقت وارد یک state می شویم این ریوارد

را دریافت میکنیم :

$V_{(s)} : z_{(s)} = \text{peace}$

الف

M \rightarrow mountain

R \rightarrow Riverside

D \rightarrow Desert

$$v_{(s)}^2 = \sum_{s'} T(s, z_{(s)}, s') [R(s, z_{(s)}, s') + \gamma v_{(s')}^2]$$

$$\rightarrow v_{(M)}^2 = \frac{1}{c} [r + \gamma v_{(R)}^2] + \frac{1}{c} [-1 + \gamma v_{(D)}^2]$$

$$v_{(R)}^2 = [r + \gamma v_{(R)}^2] \rightarrow v_{(R)}^2 = \frac{r}{1-\gamma}$$

$$v_{(D)}^2 = [-1 + \gamma v_{(D)}^2] \rightarrow v_{(D)}^2 = -\frac{1}{1-\gamma}$$

$$\rightarrow v_{(M)}^2 = \frac{1}{c} \left[r + \frac{c\gamma}{1-\gamma} \right] - \frac{1}{c} \left[+1 + \frac{\gamma}{1-\gamma} \right]$$

$$= \frac{1}{1-\gamma} - \frac{1}{c} \frac{1}{1-\gamma} \rightarrow v_{(M)}^2 = \frac{1}{c(1-\gamma)}$$

ب) در بخشی الف را evaluate کردیم که اگر $\gamma = 0.9$ باشد:

$$v_{(M)}^2 = +0, \quad v_{(D)}^2 = -10, \quad v_{(R)}^2 = 20$$

در این بخش Policy improvement می زنیم یعنی :

$$z_{i+1}(s) = \operatorname{argmax}_a Q^{z_i}(s, a)$$

Peace $\rightarrow p$
war $\rightarrow w$

$$Q^{z_i}(s, a) = \sum_{s'} T(s, a, s') [R(s, a, s') + \gamma v_{s'}^{z_i}]$$

$$\rightarrow z_{i+1}(s) = \operatorname{argmax}_a \sum_{s'} T(s, a, s') [R(s, a, s') + \gamma v_{s'}^{z_i}]$$

(s, a, s')

$$\forall_{(s, a)}: R(s, a, m) + \gamma v_m^z = 1 + \frac{9}{10} \times 0 = 0.1$$

$$\forall_{(s, a)}: R(s, a, 0) + \gamma v_0^z = -1 + \frac{9}{10} \times -10 = -10$$

$$\forall_{(s, a)}: R(s, a, R) + \gamma v_R^z = 5 + \frac{9}{10} \times 5 = 5$$

$$Q^z(m, p) = \frac{1}{5} \times 5 + \frac{1}{5} \times -10 = 0$$

$$Q^z(m, w) = \frac{1}{10} \times 0.1 + \frac{5}{10} \times -10 + \frac{4}{10} \times 5 = -1.9$$

$$\rightarrow z_{i+1}(m) = \text{war}$$

$$Q^z(R, p) = 5, \quad Q^z(R, w) = \frac{5}{10} \times 5 + \frac{5}{10} \times 0.1 = 1.5$$

$$\rightarrow z_{i+1}(R) = \text{peace}$$

$$Q^2(D, P) = -1, \quad Q^2(D, W) = 0/0$$

$$\rightarrow \boxed{r^{i+1}(D) = \text{war}}$$

(ج) الگوریتم Q-learning را با داده بازی می کنیم :

$$\text{sample} = R(s, a, s') + \gamma \max_{a'} Q(s', a')$$

$$Q(s, a) = Q(s, a) + \alpha [\text{sample} - Q(s, a)]$$

طبق این ایزود وردی، داریم :

ابتدا همه $Q(s, a)$ ها صفر است

$$\text{sample}_1 = (D, W, D, -1) \quad \text{sample}_2 = (D, W, R, 1)$$

$$\text{sample}_3 = (R, P, M, 1) \quad \text{sample}_4 = (M, P, R, 1)$$

sample 1:

$$Q(D, W) = 0 + \frac{1}{4} [-1 + 0 - 0] = -1$$

sample 2:

$$Q(D, W) = -1 + \frac{1}{4} [1 + 0 + 1] = +1$$

sample 3:

$$Q(R, p) = 0 + \frac{1}{r} [1 + 0 - 0] = 0/5$$

sample 4:

$$Q(m, p) = 0 + \frac{1}{r} [1 + \frac{1}{r} - 0] = 0/75$$

→ Q-table:

m - p	R - p	D - w
0	0	0
0	0	-1
0	0	+1
0	0/5	+1
0/75	0/5	+1

حالا همین سوال را به شکل حل میکنیم که $R_{(s)}$ باشد

یعنی وقتی از state خارج می شویم این ریوارد را دریافت کنیم:

$V_{(s)} : z_{(s)} = \text{peace}$

الف

$M \rightarrow \text{mountain}$ $R \rightarrow \text{Riverside}$ $D \rightarrow \text{Desert}$

$$v_{(s)}^2 = \sum_{s'} T(s, z_{(s)}, s') [R(s, z_{(s)}, s') + \gamma v_{(s')}^2]$$

$$\rightarrow v_{(M)}^2 = \frac{1}{2} [1 + \gamma v_{(R)}^2] + \frac{1}{2} [1 + \gamma v_{(D)}^2]$$

$$v_{(R)}^2 = [1 + \gamma v_{(R)}^2] \rightarrow v_{(R)}^2 = \frac{1}{1-\gamma}$$

$$v_{(D)}^2 = [-1 + \gamma v_{(D)}^2] \rightarrow v_{(D)}^2 = -\frac{1}{1-\gamma}$$

$$\rightarrow v_{(M)}^2 = 1 + \frac{\gamma}{2} \times \frac{1}{1-\gamma} = \frac{2-\gamma}{2-\gamma}$$

$$= \frac{2-\gamma}{2-\gamma} \rightarrow v_{(M)}^2 = \frac{2-\gamma}{2-\gamma}$$

ب) در بخشی الف را evaluate کردیم که اگر $\gamma = 0.9$ باشد:

$$v_{(M)}^2 = 0.5, \quad v_{(D)}^2 = -1.5, \quad v_{(R)}^2 = 2.5$$

در این بخش Policy improvement می زنیم یعنی:

$$z_{i+1}(s) = \operatorname{argmax}_a Q^{z_i}(s, a)$$

Peace $\rightarrow p$
war $\rightarrow w$

$$Q^{z_i}(s, a) = \sum_{s'} T(s, a, s') [R(s, a, s') + \gamma v_{(s')}^{z_i}]$$

$$\rightarrow z_{i+1}(s) = \operatorname{argmax}_a \sum_{s'} T(s, a, s') [R(s, a, s') + \gamma v_{(s')}^{z_i}]$$

$$Q^z(M, p) = \frac{1}{c} [1 + \frac{9}{16} \times c_0] + \frac{1}{c} [1 + \frac{9}{16} \times -10] = 0/0$$

$$Q^z(M, w) = \frac{1}{16} [1 + \frac{9}{16} \times 0/0] + \frac{5}{16} [1 + \frac{9}{16} \times -10] + \frac{1}{16} [1 + \frac{9}{16} \times c_0]$$

$$= 0/0 \times 9/0 + -1/3 + 10/16 = 15/160$$

$$\rightarrow z_{i+1}(M) = \text{war}$$

$$Q(R, p) = c + \frac{9}{16} \times c_0 = c_0$$

$$Q(R, w) = \frac{5}{16} [c + \frac{9}{16} \times c_0] + \frac{1}{16} [c + \frac{9}{16} \times 0/0] = 9/00$$

$$\rightarrow z_{i+1}(R) = \text{Peace}$$

$$Q(D, P) = -1 + \frac{9}{10} \times -10 = -10$$

$$Q(D, W) = -1 + \frac{9}{10} \times 5/5 = 4/5$$

$$\rightarrow 2^{i+1}(D) = \text{war}$$

بعضی ج همکار تعدادی نمی کند R روی وارد شدن یا خارج شدن state باشد.