


- (الف) انزایی درگی ها می باشد منجر به بزرگ تر شدن hypothesis space می شود
- (ب) انزایی پیچیدگی مدل و توابع می باشد منجر به بزرگ تر شدن hypothesis space می شود

(ج) چون بین داده ها همبستگی وجود دارد اگر داده ها خطا کمتری داشته باشند و باعث انزایی overfitting می شود یعنی variance بزرگتر می شود در کل با کم شدن پیچیدگی مدل می شود اگر ویژگی های تکراری را حذف کنیم Var کم می شود و bias بزرگتر می شود در کل مدل ساده تر شدن و از overfit دوری شویم

(د) اولی: طبیعتاً تقریب داریم  $Bias = E[f_{(2)}] - f_{(2)}$  و ثانیاً حتی اگر تعداد داده ها را زیاد کنیم متوجه می شویم که بایاسی کم نمی شود و از صحت مسئله می بینیم این گزاره نادرست است



گزاره دوم نیز نادرست است خطای train همیشه کم می شود و به سمت overfit می رود و خطای validation و test تا جایی که می شود و سپس زیاد می شود

(۴) الف) در درخت تصحیح خط زمانی اتفاق می‌افتد از  $\lambda$  های یکسان  $\lambda$  های

مختلن دائرة باغ در این جدول  $1 \rightarrow 110$  خواص رنت  $110 \rightarrow 5$

در جدول داریم به‌طور ؟  $111 \rightarrow$  پس بین  $1$  و  $2$  داریم در نمودار عمل کنند

که خط رخ ردید پس در مجموع  $2$  خط داریم که می‌شود:

$$\frac{2}{11} \approx 18.18\%$$

$$\begin{array}{l} 111 \rightarrow 5 \\ 111 \rightarrow 1 \end{array}$$

$$111 \rightarrow ?$$

$$\begin{array}{l} 110 \rightarrow 1 \\ 110 \rightarrow 1 \\ 110 \rightarrow 5 \end{array}$$

$$110 \rightarrow 1$$

ب) خواص انتات کیه زمانی که نیچر جا گفته ای تعداد را داریم .

فرض کنید  $c$  تا کلاسی و  $k$  تا داده داریم

زمانی که مقدار نیچرهای تمام داده ها یکسان است حداقل  $\lceil \frac{k}{c} \rceil$  تعداد

درست است در نتیجه خطا می‌شود  $\frac{k - \lceil \frac{k}{c} \rceil}{k}$

انتات (با اشترا):  $k=2$  فرض: برای  $k \leq n$  برقرار است حکم:  $k=n$  هم برقرار است.

برهان خط: فرض کنید زمانی که نیچر جا گفته ای  $k$  را داریم که درخت بر حسب آن جا می‌شود، حداقل خطا را داریم در این صورت مثلاً اگر تعداد درست  $t_i$  و  $t_i < n$

باشد آنگاه تعداد درست  $\lceil \frac{t_i}{c} \rceil$  و در نتیجه تعداد کل درست  $\sum_i \lceil \frac{t_i}{c} \rceil$

همچنین  $\lceil \frac{\sum_i t_i}{c} \rceil \leq \sum_i \lceil \frac{t_i}{c} \rceil$  و زمانی که نیچر جا گفته ای حداقل تعداد درست

می‌شود که با فرض درست‌نمایی است و ثابت می‌شود حکم برقرار است.  $\lceil \frac{\sum_i t_i}{c} \rceil = \lceil \frac{n}{c} \rceil$

(3)

الف) فرض کنید  $k$  کلاس داریم که به شکل  $\{k, \dots, 2, 1\}$   $D_y =$   
 $\downarrow \quad \downarrow \quad \downarrow$   
 $w_1 \quad w_2 \quad w_k$   
 تعریف شده اند

و تبدیلی به شکل  $X \rightarrow Y$  داریم که  $X$  نیز یک بردار از فضای  $R^n$  است  
 (یعنی  $n$  تا Feature داریم)  
 با در نظر گرفتن BIAS به شکل  $[1]$  و  $\downarrow$   
 به فضای  $R^{n+1}$  می رود

فضای  $R^n$  توسط  $k$  تا بردار  $w_1, \dots, w_k$  به  $k$  دسته تقسیم شده است  
 که بردار  $w_i$  مربوط به کلاسی  $i$  است.  
 با این توصیفات، خواص دات :

(دقت کنید برای اضافه کردن بایاس باید  $w = \begin{bmatrix} w \\ BIAS \end{bmatrix}$  و  $x = \begin{bmatrix} x \\ 1 \end{bmatrix}$  نوشته شود.)

$$Pr_{w_1 \dots w_k}(Y=i | X=x) = \frac{e^{w_i^T x}}{\sum_k e^{w_k^T x}}$$

$e^{w_k^T x} = e^0 = 1$

که طبیعتاً گفته سوال  $w_k = 0$  قرار می دهیم که خواص دات  $\uparrow$

$$Pr_{w_1 \dots w_k}(Y=i | X=x) = \frac{e^{w_i^T x}}{1 + \sum_{j=1}^{k-1} e^{w_j^T x}}$$

ج) حالا بردار  $w_1, w_2, \dots, w_{k-1}$  را باید Learn کنیم که هر  
 بردار از فضای  $R^{n+1}$  است که  $n$  تعداد feature های  
 $x$  است. اگر  $BIAS$  را صرف گیریم در کل  $n \times (k-1)$  مقدار  
 مجهول داریم اما اگر  $BIAS$  را در نظر بگیریم  $(n+1) \times (k-1)$   
 مقدار مجهول خواهیم داشت که آنرا از  $BIAS$  صرف نظر می کنیم

---

$n$  داده به شکل  $(x_1, y_1), \dots, (x_n, y_n)$  داریم  
 داده ها را به شکل iid در نظر می گیریم که  $y_i$  به شکل  $1, 0, \dots, k$  می باشد

$$P(y_{1:n} | x_{1:n}) = \prod_{i=1}^n P(y = y_i | x = x_i; w_1, \dots, w_k)$$

$$\rightarrow L_{w_{1:k}} = \sum_{i=1}^n \ln P(y = y_i | x = x_i)$$

$$= \sum_{i=1}^n \ln \frac{e^{w_{y_i}^T x_i}}{1 + \sum_{l=1}^{k-1} e^{w_l^T x_i}}$$

$$= \sum_{i=1}^n \left[ w_{y_i}^T x_i - \ln \left( 1 + \sum_{l=1}^{k-1} e^{w_l^T x_i} \right) \right]$$

$$\nabla_{w_k} L = \sum_{i=1}^n \left[ I_{(i,k)} x_i - \frac{x_i e^{w_k^T x_i}}{1 + \sum_{l=1}^{k-1} e^{w_l^T x_i}} \right] \quad (2)$$

$$I_{(i,k)} = \begin{cases} 1 & i=k \\ 0 & i \neq k \end{cases}$$

$$\rightarrow \nabla_{w_k} L = \sum_{i=1}^n x_i \left[ I_{(i,k)} - P(Y=k | X=x_i) \right]$$

$$f_{w_{1:k}} = L_{w_{1:k}} - \frac{\lambda}{r} \sum_{j=1}^{k-1} \|w_j\|^2 \quad (3)$$

$$\hookrightarrow \nabla_{w_k} f = \underbrace{\nabla_{w_k} L}_{\text{از بخش 2}} - \lambda w_k$$

از بخش 2

(۴)

$$y = \begin{bmatrix} y^{(0)} \\ \vdots \\ y^{(n)} \end{bmatrix}_{n \times 1} \quad X = \begin{bmatrix} 1 & -x_1^T & - \\ 1 & -x_2^T & - \\ \vdots & \vdots & \vdots \\ 1 & -x_n^T & - \end{bmatrix}_{(n+1) \times 3} \quad w = \begin{bmatrix} w_0 \\ \vdots \\ w_m \end{bmatrix}_{(m+1) \times 1}$$

توین ادر  $x$  به خط Bias،  $w_0$  افان نه شده است.  $x_n$  متغیر داده ی  $n$  له  $1 = (y^{(n)})$

که داده  $L$  به شکل:  $L = \frac{1}{2} \|y - Xw\|^2$  تعریف می شود

که باید با حرکت روی  $w$   $\min$  شود

$$L = \frac{1}{2} (y - Xw)^T (y - Xw) = \frac{1}{2} (y^T y - y^T Xw - w^T X^T y + w^T X^T Xw) \Rightarrow \nabla_w L = \nabla_w \frac{1}{2} (y^T y - y^T Xw - w^T X^T y + w^T X^T Xw) = -X^T y + X^T Xw \stackrel{=0}{\rightarrow} \hat{w} = (X^T X)^{-1} X^T y$$

حال به حل سوال می پردازیم:

الف) گاهی است جای ماتریس  $X$ ،  $x_j$  که ستن  $X$  له  $1 =$  وارار

$$w_j = (x_j^T x)^{-1} x_j^T y = \frac{x_j^T y}{x_j^T x}$$

یا از راه دیگر:

$$L = \frac{1}{2} \sum_{i=1}^n (y_i - w_j x_{ji})^2$$

از  $x_j$  یعنی ستن  $X$  له صط  $x_{ji}$

ماتریس  $X$

$$\frac{\partial L}{\partial w_j} = \sum_{i=1}^n (y_i - w_j x_{ji}) (-x_{ji}) = 0$$

$$\rightarrow \sum_{i=1}^n y_i x_{ji} = w_j \sum_{i=1}^n x_{ji}^2$$

$$\rightarrow x_j^T y = w_j x_j^T x_j \rightarrow w_j = \frac{x_j^T y}{x_j^T x_j}$$

ب) چون تون ها برصع خوده يسي ضرب داخل آن ها صرا = يني :

$$x^T x = \text{diag}(|x_1|^2, \dots, |x_m|^2)$$

$$\rightarrow (x^T x)^{-1} = \text{diag}\left(\frac{1}{|x_1|^2}, \dots, \frac{1}{|x_m|^2}\right)$$

خواته يني غير آن در صراط ي شونه

$$\rightarrow w = (x^T x)^{-1} x^T y \rightarrow w_j = ((x^T x)^{-1} x^T y)_j = (x^T x)^{-1}_j (x^T y)_j$$

$$(x^T x)^{-1}_j = \frac{1}{|x_j|^2} \rightarrow w_j = \frac{(x^T y)_j}{|x_j|^2} = \frac{x_j^T y}{x_j^T x_j}$$

$$\rightarrow w_j = \frac{x_j^T y}{x_j^T x_j}$$

از بعضی الت و ب نتیجه می گیریم مباحث ستل  $w_j$  ها و مباحثی هنرمات  $w_j$  ها  
 ها معرفی به جوا - بهینه و رررر

(۱) صفت رررر  $X = \begin{bmatrix} 1 & -x_1^T \\ \vdots & \vdots \\ 1 & -x_n^T \end{bmatrix}$  د ارجح :  $n \times (n+1)$

$$X^T X = \begin{bmatrix} n & \text{sum}(x_j) \\ \text{sum}(x_j) & |x_j|^2 \end{bmatrix}$$

$\text{sum}(x) =$  جمع تمام مقادیر  
 نون  $x$  یعنی  
 $= \sum_i x^{(i)}$

$$X^T y = \begin{bmatrix} \text{sum}(y) \\ x_j^T y \end{bmatrix}$$

$(X^T X)^{-1} = \frac{\begin{bmatrix} |x_j|^2 - \text{sum}(x_j)^2 \\ -\text{sum}(x_j) & n \end{bmatrix}}{n |x_j|^2 - \text{sum}(x_j)^2}$

name  $\phi = n |x_j|^2 - \text{sum}(x_j)^2$

$$w = (X^T X)^{-1} X^T y = \frac{1}{\phi} \begin{bmatrix} |x_j|^2 - \text{sum}(x_j)^2 \\ -\text{sum}(x_j) & n \end{bmatrix} \begin{bmatrix} \text{sum}(y) \\ x_j^T y \end{bmatrix}$$

$$\rightarrow w_j = \frac{n x_j^T y - \text{sum}(x_j) \text{sum}(y)}{n |x_j|^2 - \text{sum}(x_j)^2} = \frac{\frac{x_j^T y}{n} - \frac{\text{sum}(x_j) \text{sum}(y)}{n}}{\frac{|x_j|^2}{n} - \left(\frac{\text{sum}(x_j)}{n}\right)^2}$$

$$= \frac{E[x_j y] - E[x_j] E[y]}{E[x_j^2] - E^2[x_j]} = \frac{\text{Cov}(x_j, y)}{\text{Var}(x_j)} \rightarrow \phi = n \text{Var}(x_j)$$



بسط دوم :

$$w_0 = \frac{\text{sum}(y) |x_0|^2 - \text{sum}(x_0) (x_0^T y)}{n^2 \text{var}(x_0)}$$

$$= \frac{n^2 E[y] E[x_0^2] - \cancel{n^2} E[x_0] E[x_0 y]}{\cancel{n^2} \text{var}(x_0)}$$

$$= \frac{E[y] E[x_0^2] - E[y] E^2[x_0] + E[y] E^2[x_0] - E[x_0] E[x_0 y]}{\text{var}(x_0)}$$

$$= \frac{E[y] \text{var}(x_0) - E[x_0] \text{Cor}(x_0, y)}{\text{var}(x_0)}$$

$\frac{\text{Cor}(x_0, y)}{\text{var}(x_0)} = w_1$   
طبیقات

$$= E[y] - E[x_0] w_1$$

$$\rightarrow w_0 = E[y] - w_1 E[x_0]$$